基於 NHANES 醫療數據之前期糖尿病風險因子分析與機器學習預測模型

一、 摘要 (Abstract)

本研究運用美國國家健康與營養體檢調查（NHANES 2017-2018）的公開醫療數據，探討「未被診斷為糖尿病」之成年人中，家族病史與自覺風險對其生理指標與健康行為的影響。研究不僅採用複雜抽樣加權（Complex Survey Weighting）進行統計推論；更進一步導入隨機森林（Random Forest）機器學習演算法建立預測模型。研究結果指出，帶有家族史與高自覺風險者的生理指標(如血糖、BMI）已顯著偏高；但在機器學習的多變數綜合評估下，「年齡」與「BMI」才是預測前期糖尿病最重要的關鍵因子。本研究為未來的公衛預防政策與醫療資源分配提供了有力的數據支持。

二、 研究動機與背景 (Introduction)

糖尿病為台灣與全球主要慢性病。在臨床經驗中，往往觀察到兩種現象：第一，許多帶有家族病史的民眾自認健康，直到驗出高血糖才驚覺風險；第二，部分擁有高「自覺風險」的族群，知道糖尿病的嚴重性卻缺乏實際的行為改變。 因此，本專題設立兩大核心研究問題：

- **Q1（生理層面）**：在「尚未被診斷」的成年人中，帶家族病史者的平均空腹血糖與糖化血色素是否已顯著偏高？
- **Q2（行為層面）**：覺得自己可能罹患糖尿病（自覺風險高）的人，是否真的在 BMI、飲食、運動行為上表現得更健康？

三、 資料來源與研究方法 (Methodology)

1. **資料來源與樣本篩選**：合併 NHANES 2017-2018 包含問卷、血糖檢驗、飲食、身體活動等 7 份資料表，嚴格篩選出「未被診斷糖尿病（DIQ010=2)」之有效樣本。
2. **統計分析 (Statistical Analysis)**：使用 R 語言 survey 套件處理 NHANES 複雜抽樣設計。透過加權 t 檢定比較單一變數差異；並建立加權多變項線性與羅吉斯迴歸，控制共變數以尋找自覺風險的獨立影響力。
3. **機器學習預測 (Machine Learning)**：定義「前期糖尿病」(空腹血糖 >= 100 或 HbA1c >= 5.7)。採用 caret 套件之隨機森林（Random Forest）演算法，搭配 5-Fold 交叉驗證訓練模型，產出特徵重要性指標。

四、 研究結果 (Results)

4.1 家族史的隱形風險 (Q1 統計發現)

加權 t 檢定結果顯示，有家族病史者即使尚未確診糖尿病，其生理指標已處於較高的風險區間。有家族史者的平均空腹血糖（FPG）為 **107.86 mg/dL**，顯著高於無家族史者的 **102.45 mg/dL**（p = 0.0491，平均差距達 5.40 mg/dL)；而在

糖化血色素（HbA1c）方面，有家族史者平均為 **5.57%**，亦逼近 5.7% 的前期糖尿病臨界點。

```
> # Q1: 家族史對血糖的影響
> mean_glu <- svyby(~ LBXGLU + LBXGH, ~ fh_yes, des1, svymean, vartype = "ci")
> mean_glu
      fh_yes   LBXGLU    LBXGH ci_l.LBXGLU ci_l.LBXGH ci_u.LBXGLU ci_u.LBXGH
FALSE  FALSE 102.4545 5.435505    101.2663   5.393397    103.6427   5.477614
TRUE    TRUE 107.8572 5.566332    102.8681   5.436730    112.8464   5.695935
> glu_t <- svyttest(LBXGLU ~ fh_yes, des1)
> glu_t

        Design-based t-test

data:  LBXGLU ~ fh_yes
t = 2.1545, df = 14, p-value = 0.0491
alternative hypothesis: true difference in mean is not equal to 0
95 percent confidence interval:
  0.0244055 10.7810131
sample estimates:
difference in mean
          5.402709
```

圖表說明：上圖為加權 t 檢定結果，證實家族史對未確診者的空腹血糖有顯著的推升作用。

4.2 自覺風險之生理與行為探討（Q2 統計發現）

為探討「自覺風險」與實際行為/生理數值的關聯，本研究進行了單變數與多變項分析：

1. **BMI 單變數分析（Q2A）**：加權 t 檢定指出，有自覺風險者的 BMI 顯著高於無自覺風險者（p = 0.0125），兩者平均 BMI 差距達到 **3.80 kg/m²**。

```
> # Q2A: 自覺風險對 BMI 的影響
> bmi_t <- svyttest(bmi ~ risk_self, des1)
> bmi_t

        Design-based t-test

data:  bmi ~ risk_self
t = 2.8626, df = 14, p-value = 0.01254
alternative hypothesis: true difference in mean is not equal to 0
95 percent confidence interval:
 0.9536149 6.6526145
sample estimates:
difference in mean
          3.803115
```

2. **多變項控制分析（Q2B 預測 BMI）**：在控制年齡、性別、飲食熱量與運動量後，加權多變項線性迴歸顯示，自覺風險仍與較高的 BMI 呈現顯著正相關（Estimate = 3.785，p = 0.0146）。這代表即使排除了其他生活型態干擾，「肥胖」本身極可能是引發民眾產生「自覺罹患糖尿病風險」的強烈來源。

```
> # Q2B: 加權多變項線性回歸 (預測 BMI)
> model_2b <- svyglm(bmi ~ risk_self + RIDAGEYR + RIAGENDR + DR1TKCAL + PAD615, design = des1)
> summary(model_2b)

Call:
svyglm(formula = bmi ~ risk_self + RIDAGEYR + RIAGENDR + DR1TKCAL +
    PAD615, design = des1)

Survey design:
svydesign(id = ~SDMVPSU, strata = ~SDMVSTRA, weights = ~WTMEC2YR,
    nest = TRUE, data = no_dx)

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    3.020e+01  1.744e+00  17.318 8.73e-09 ***
risk_selfTRUE  3.785e+00  1.285e+00   2.946   0.0146 *
RIDAGEYR      -4.212e-02  3.339e-02  -1.261   0.2358
RIAGENDR2      7.166e-01  7.465e-01   0.960   0.3597
DR1TKCAL       2.039e-05  3.835e-04   0.053   0.9586
PAD615        -2.512e-03  2.192e-03  -1.146   0.2785
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for gaussian family taken to be 46.08589)

Number of Fisher Scoring iterations: 2
```

3. **行為改變困境（Q2C 預測運動達標）**：加權羅吉斯迴歸探討自覺風險是否促成「每週 150 分鐘中高強度運動」的行為改變。結果顯示，在控制共變數後，民眾「是否有自覺風險」對於是否規律運動**完全不具統計顯著性**（p = 0.9766）。這強烈點出了「知易行難」的公衛困境：單純的風險認知，並未成功轉化為實際的健康行為。

```
> # Q2C: 加權 logistic 回歸 (預測運動達標)
> model_2c <- svyglm(active_150 ~ risk_self + RIDAGEYR + RIAGENDR + DR1TKCAL + bmi,
+                    design = des1, family = quasibinomial())
> summary(model_2c)

Call:
svyglm(formula = active_150 ~ risk_self + RIDAGEYR + RIAGENDR +
    DR1TKCAL + bmi, design = des1, family = quasibinomial())

Survey design:
svydesign(id = ~SDMVPSU, strata = ~SDMVSTRA, weights = ~WTMEC2YR,
    nest = TRUE, data = no_dx)

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.3204150  0.3966273   3.329  0.00763 **
risk_selfTRUE -0.0077257  0.2568913  -0.030  0.97660
RIDAGEYR      -0.0190608  0.0059013  -3.230  0.00902 **
RIAGENDR2     -0.5098963  0.2037839  -2.502  0.03133 *
DR1TKCAL      -0.0001016  0.0001087  -0.935  0.37183
bmi           -0.0072843  0.0183271  -0.397  0.69938
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for quasibinomial family taken to be 1.003368)

Number of Fisher Scoring iterations: 4
```

4.3 前期糖尿病高風險預測模型（機器學習發現）

除了傳統統計推論，本專題成功訓練了隨機森林（Random Forest）預測模型，針對「未確診」的潛藏風險族群進行前期糖尿病預測。模型在測試集上達到 60.82% 的整體準確率（Accuracy）。對於模糊地帶的亞健康族群而言，此模型具備客觀的參考價值。

更重要的是，根據模型輸出的「特徵重要性（Feature Importance）」分析，在綜合評估所有變數時，**「年齡（RIDAGEYR）」**與**「BMI」**是預測前期糖尿病最具決定性的兩大因子，其重要性分數遙遙領先；相對而言，「家族病史（fh_yes）」雖然在單變數統計中顯著，但在 AI 模型的整體多變數評估下，其預測重要性僅排在第四位。

```
> # 預測測試集並印出結果
> rf_pred <- predict(rf_model, newdata = test_data)
> confusionMatrix(rf_pred, test_data$Pre_Diabetes)
Confusion Matrix and Statistics

          Reference
Prediction HighRisk Normal
  HighRisk       44     21
  Normal         17     15

               Accuracy : 0.6082
                 95% CI : (0.5039, 0.7058)
    No Information Rate : 0.6289
    P-Value [Acc > NIR] : 0.7025

                  Kappa : 0.1412

 Mcnemar's Test P-Value : 0.6265

            Sensitivity : 0.7213
            Specificity : 0.4167
         Pos Pred Value : 0.6769
         Neg Pred Value : 0.4688
             Prevalence : 0.6289
         Detection Rate : 0.4536
   Detection Prevalence : 0.6701
      Balanced Accuracy : 0.5690

       'Positive' Class : HighRisk
```

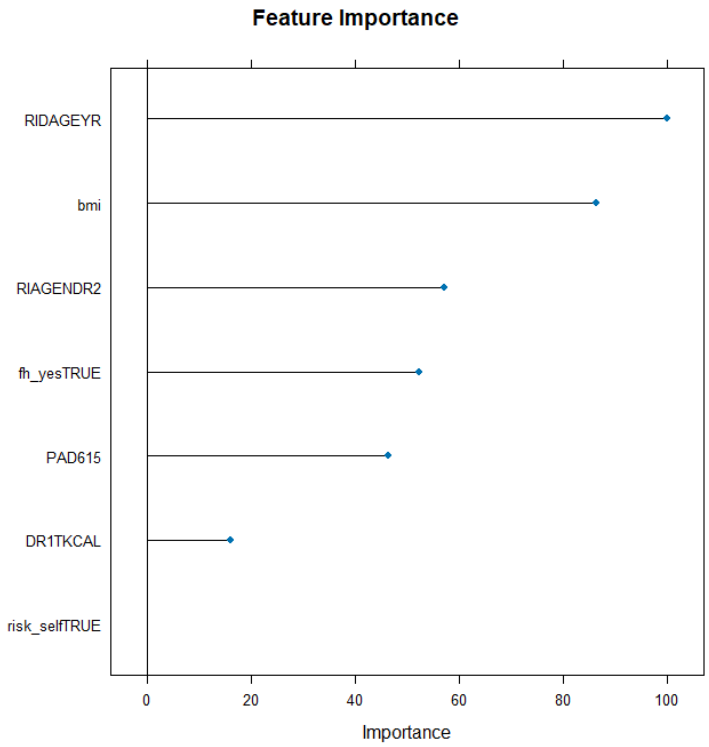

說明：隨機森林預測結果顯示**年齡**與 **BMI** 為影響前期糖尿病風險的最關鍵特徵。

五、 結論與臨床建議 (Conclusion & Recommendations)

本研究透過嚴謹的統計加權與機器學習雙軌分析，得出以下結論：

1. **破除「單靠家族史預警」的迷思**：傳統單變數統計雖指出家族史與高血糖顯著相關，但經過 AI 模型的多變數大數據綜合評估，**年齡老化與肥胖（BMI）才是引發前期糖尿病最核心的元凶**。
2. **「知行不一」的公衛挑戰**：民眾可能因為自身過重（BMI 較高）而產生罹患糖尿病的自覺風險，但這種危機感並未能有效轉化為規律運動的行為改變（Q2C 證實）。
3. **政策建議**：醫療衛教不應只侷限於有家族史的民眾。針對高齡與過重族群推動「具強制力或誘因」的全民減重與運動計畫(而非僅停留在風險宣導)，將是預防糖尿病最有效率的防線。